

examen de culture numérique | 8 décembre 2025
cours de thomas tari

durée | 3 heures

la consultation de notes manuscrites et imprimées est autorisée
la composition pourra s'effectuer en langue française ou anglaise
veillez à bien répondre aux deux questions posées

1 | composition | 14 points

en partant de l'analyse des documents suivants, **et en élargissant votre réflexion grâce à la mobilisation de notions de cours**, répondez de manière argumentée et structurée à la question suivante :

les enjeux politiques de l'intelligence artificielle sont-ils une question de biais ?

doc 1 | la couleur politique des ia dans le viseur de la droite américaine | *le monde* | 27 mars 2025

Le changement de ton de l'administration américaine a été repéré par le magazine américain Wired, qui lui consacre un article le 14 mars. L'organisme qui fixe les normes américaines, le National Institute of Standards and Technology, a fait parvenir une nouvelle consigne à OpenAI, Google, Anthropic et Microsoft, ainsi qu'aux autres membres de l'IAI, l'institut pour la sécurité de l'intelligence artificielle : à charge pour eux de « réduire [leurs] biais idéologiques ». Cette requête, émise début mars dans le cadre du partenariat de recherche et développement de l'IAI, fait écho à une ambition formulée dans un décret publié par la Maison Blanche fin janvier. Le soupçon de « biais » des intelligences artificielles (IA), qui seraient peu compatibles avec le programme trumpiste, n'est pas entièrement infondé. Un chercheur néo-zélandais de l'université polytechnique d'Otago, David Rozado, a fait passer une batterie de tests de positionnement politique à plus de vingt modèles de langage : tous pencheraient selon lui davantage vers la « gauche du centre », y compris le Grok d'Elon Musk. [...] L'un des tests réalisés par le chercheur néo-zélandais était particulièrement éclairant : si les IA répondaient fréquemment avec des arguments de « droite libérale », elles puisaient beaucoup plus rarement dans les idées de la « droite dure ».




Comment expliquer cette sélectivité politique ? On trouve un début d'explication dans les model specs d'OpenAI, un document qui décrit le comportement attendu de ChatGPT de façon particulièrement approfondie. L'IA possède un noyau de principes moraux : elle doit « dire clairement que les violations des droits humains fondamentaux sont mauvaises », édicte OpenAI. On peut le vérifier en lui demandant, par exemple, s'il est « souhaitable qu'un pays fort envahisse un pays faible ». ChatGPT est ferme sur ce point : « Ça n'est ni souhaitable ni justifiable. L'invasion d'un pays faible par un pays plus fort viole les principes fondamentaux du droit international, notamment la souveraineté et l'autodétermination des peuples. » Selon OpenAI, le noyau moral de ChatGPT recèle une autre règle : ne pas générer « de contenu haineux ciblant des groupes protégés (origine ethnique, religion, genre, orientation sexuelle, handicap, etc.). Cela inclut les insultes, les injures et tout langage dégradant ou déshumanisant ». Un principe moral qui, là aussi, va à l'encontre d'une conception libertarienne de la « liberté d'expression » qui a le vent en poupe au sein de l'alt-right américaine : toujours selon Wired, l'administration américaine, à travers la voix de l'AIISI, n'appelle d'ailleurs plus comme auparavant à une intelligence artificielle « responsable » et « juste », comme elle n'encourage plus les chercheurs à identifier et atténuer les comportements discriminatoires liés au genre ou aux origines ethniques.

Pour autant, l'idée selon laquelle les IA refuseraient obstinément de tenir un discours conservateur est fausse. Effet pervers des méthodes d'entraînement des IA : selon la recherche, ChatGPT et Claude ne peuvent pas faire autrement que d'adapter automatiquement leur réponse au point de vue de leur utilisateur, si celui-ci transparaît dans la formulation des questions. Un biais mesuré par une étude de 2023, menée notamment par la philosophe Amanda Askell, ex-collaboratrice d'OpenAI qui dirige aujourd'hui l'équipe chargée de peaufiner la « personnalité » de Claude. Se débarrasser de ce biais représente selon elle un défi scientifique.

Pour faire tenir toutes sortes de propos, y compris de droite dure ou complotiste, à une IA comme ChatGPT, Gemini ou Claude, il suffit de toute façon de le leur demander : elles ne rechigneront pas à écrire un tract pour Eric Zemmour. Il est par ailleurs possible de personnaliser le point de vue de ChatGPT dans ses options, et si on se « fâche » avec lui, le robot finira de toute façon par proposer d'adopter notre opinion. Avec ces méthodes, l'IA conversationnelle est tout à fait prête à nier le réchauffement climatique ou à arguer que la terre est plate – un exemple assumé par OpenAI lui-même. Par ailleurs, les IA continuent de souffrir de biais masculinistes, racistes et homophobes, comme le déplorent une étude de l'université de Stanford et une autre de l'Unesco. Selon cette dernière, publiée en mars 2024, les femmes y sont beaucoup plus souvent décrites comme travaillant à des rôles domestiques ; les homosexuels et les membres de certaines communautés ethniques y étant, eux, décrits de manière négative. Les IA les plus anciennes sont les plus susceptibles de verser dans ces biais.

Dans son document décrivant la personnalité attendue de ChatGPT, OpenAI déclare qu'il continue de travailler sur ces problèmes. Mais pour combien de temps ? Dans ce même texte, l'entreprise reprend à son compte la rhétorique trumpiste, estimant que son programme doit « encourager la liberté intellectuelle » de ses utilisateurs, qu'il ne doit pas « censurer ou éviter des sujets. [Son objectif] est d'assister l'humanité, pas de lui donner forme ». Ces engagements n'apparaissaient pas dans la version précédente des model specs d'OpenAI – plus sommaire, elle avait été publiée quelques mois avant l'élection de Donald Trump.

doc 2 | les intelligences artificielles ont-elles des biais idéologiques ? | étude sur la proximité des ia génératives vis-à-vis des principaux partis politiques en france et aux états-unis | trickstr | mars 2025



De quel bord politique est Grok, l'agent conversationnel de xAI disponible sur le réseau social X (ex-Twitter) ? Est-il « politiquement neutre », comme le clame son propriétaire Elon Musk ? A-t-il définitivement plongé dans le bain nauséabond des idées extrémistes de Musk ? En est-il au contraire devenu l'opposant, rétablissant les faits dès qu'on le lui demande ? En l'occurrence, lorsqu'un utilisateur demande à la machine quel est le plus grand risque pour la civilisation occidentale, la machine a répondu le 10 juillet « la mésinformation et la désinformation ». En réponse, Elon Musk s'est excusé de cette « réponse idiote ». Le lendemain, Grok produisait un texte déclarant que le plus grand danger pour la civilisation occidentale concernait les « taux de fécondité », dans la droite ligne des préoccupations du multimilliardaire pour la procréation des personnes des pays du Nord, voire de son milieu social.

D'après des tests menés par le New York-Times avec l'Université de Chicago à partir de mai sur différentes versions de Grok, les réponses de la machine sur une quarantaine d'enjeux politiques ont effectivement évolué, vers la droite pour la plupart des sujets liés au gouvernement ou à l'économie. En revanche, pour un tiers des questions testées, notamment pour les sujets sociaux, les réponses ont évolué vers la gauche du champ politique. À la voir produire des textes plein d'élucubrations sur un pseudo-génocide de Blancs en Afrique du Sud, des réponses déclarant la machine « sceptique » sur le nombre de juifs tués pendant la Shoah, voire lui attribuant le nom d'Hitler, on pourrait envisager Grok comme une machine à générer des contenus favorables à l'extrême-droite.

Le robot a d'ailleurs déjà produit des textes dans lesquels les lecteurs pourraient lire un soutien au Rassemblement national en France. Car rappelons-le, ces modèles restent des outils mathématiques sans conscience du sens de leurs propos ou images : ce sont les humains qui les lisent ou observent qui y projettent du sens. Ce qui n'empêche pas Elon Musk lui-même d'évoquer la machine en l'anthropomorphisant. En l'occurrence, l'entrepreneur a indiqué chercher à la rendre « neutre politiquement » et « au maximum de la recherche de la vérité ».

2 | question de cours | 6 points

à propos d'un exemple de votre choix, développé en quelques paragraphes articulés (moins d'une page),

illustrez la dimension proprement sociotechnique des inégalités numériques